

Algoritmos de Optimización en Problemas NP en el Sector Salud

Cristhian Marecos

Universidad Nacional de Itapua, Facultad de Ingeniería
Encarnacion, Paraguay
cristhianmarecos@fiuni.edu.py

Jorge Candia

Universidad Nacional de Itapua, Facultad de Ingeniería
Encarnacion, Paraguay
jorgecandia@fiuni.edu.py

Abstract

Este estudio revisa diversas técnicas de optimización aplicadas a problemas NP en el sector salud, abordando retos en áreas críticas como la gestión de citas, la cadena de suministro, el enrutamiento de emergencias, la programación de turnos y la asignación de recursos. La programación estocástica se utiliza para mejorar la eficiencia en la programación de citas hospitalarias, reduciendo los tiempos de espera a través de modelos que manejan la incertidumbre en los tiempos de llegada de los pacientes. Los algoritmos genéticos y la Optimización por Colonia de Hormigas (ACO) optimizan la cadena de suministro, permitiendo una reducción de costos en inventarios y transporte. En el contexto de los departamentos de emergencia, los modelos de colas multiclase con simulación permiten una asignación precisa de personal y recursos, mientras que el uso combinado de recocido simulado y aprendizaje por refuerzo optimiza los turnos de enfermería, mejorando la satisfacción laboral. Para el enrutamiento de ambulancias en ciudades inteligentes, el algoritmo Harris Hawks Optimization (HHO) y el algoritmo A* muestran mejoras en los tiempos de respuesta de emergencia, optimizando rutas en condiciones variables de tráfico. La simulación estocástica también se aplica en la programación de quirófanos, maximizando la utilización de estos mediante algoritmos heurísticos. Finalmente, el Enjambre de Partículas (PSO) y la programación matemática se emplean para una asignación eficiente de recursos en hospitales, contribuyendo a reducir costos operativos y a mejorar la calidad de la atención. Estos enfoques destacan el potencial de los algoritmos de optimización en mejorar la eficiencia operativa y la satisfacción en el sector salud, aunque enfrentan desafíos relacionados con la disponibilidad de datos en tiempo real y la integración tecnológica.

CCS Concepts

• **Applied computing** → **Health care information systems.**

Keywords

Optimización, Algoritmos heurísticos, Programación estocástica, Salud, Problemas NP

ACM Reference Format:

Cristhian Marecos and Jorge Candia. 2018. Algoritmos de Optimización en Problemas NP en el Sector Salud. In . ACM, New York, NY, USA, 5 pages. <https://doi.org/XXXXXXX.XXXXXXX>

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than the author(s) must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.

Itapua Exposition, Noviembre 2024, Encarnacion, Paraguay

© 2018 Copyright held by the owner/author(s). Publication rights licensed to ACM.
ACM ISBN 978-1-4503-XXXX-X/18/06
<https://doi.org/XXXXXXX.XXXXXXX>

1 Introducción

La creciente complejidad en la gestión de sistemas de salud modernos plantea numerosos desafíos, especialmente en áreas críticas como la asignación de recursos, la gestión de rutas de emergencia, y la optimización de inventarios. Estos problemas pertenecen a la clase NP, caracterizados por su alta complejidad computacional, que dificulta encontrar soluciones óptimas en tiempos razonables.

Algunos de los problemas clásicos NP en el sector salud incluyen la programación de citas médicas, la gestión de la cadena de suministro, el enrutamiento de ambulancias, y la asignación de recursos en tiempo real. La dificultad de estos problemas reside en la necesidad de encontrar soluciones que minimicen el costo o maximicen la eficiencia operativa dentro de restricciones temporales y de recursos. Estos problemas suelen ser abordados mediante algoritmos heurísticos y metaheurísticos, como los algoritmos genéticos, la programación estocástica, y técnicas de optimización basadas en inteligencia artificial.

1.1 Clasificación de Problemas Abordados

Optimización de recursos: Se emplean algoritmos como la programación estocástica y los algoritmos genéticos para optimizar el uso de recursos críticos, como inventarios y personal.

Planificación de turnos: Técnicas de recocido simulado y aprendizaje por refuerzo permiten mejorar la programación de turnos, reduciendo costos y mejorando la satisfacción del personal.

Enrutamiento de emergencias: Algoritmos como HHO y A* se utilizan en el enrutamiento de ambulancias, mejorando tiempos de respuesta en situaciones de emergencia.

Programación de citas: El uso de programación estocástica para reducir tiempos de espera es clave en la programación de citas, como en los estudios de Sun et al.

Glosario de Abreviaciones y Palabras Clave

- **C.T.** - Costo Total: Representa el costo combinado de inventario y distribución.
- **Inv** - Inventario: Costo asociado al mantenimiento y gestión del inventario.
- **Dist.** - Distribución: Costo relacionado con la distribución de suministros.
- **Gen.** - Generación: Número de iteraciones en el algoritmo genético.
- **Pob.** - Población: Tamaño de la población en el algoritmo genético.
- **Mut.** - Mutación: Tasa de mutación aplicada en el algoritmo genético.
- **Élite** - Tamaño de la élite: Número de mejores soluciones que se conservan en cada generación.

2 Estado del Arte

2.1 Programación Estocástica

Khalilpourazari [8] presenta modelos avanzados de programación estocástica y aprendizaje automático que abordan problemas de planificación, programación y predicción en el sector salud. Estos enfoques permiten gestionar incertidumbres en tiempos de servicio y disponibilidad de personal, optimizando recursos y mejorando la eficiencia operativa en hospitales.

Sun et al. [17] propusieron un enfoque de programación estocástica para la programación de citas en hospitales, permitiendo reducir los tiempos de espera y el tiempo de inactividad de los equipos. Este modelo de dos etapas maneja la incertidumbre en los tiempos de llegada de pacientes externos e internos, logrando una mejora del 23% en eficiencia hospitalaria.

2.2 Optimización Estocástica en la Recolección de Residuos Médicos Infecciosos

La recolección de residuos médicos infecciosos, especialmente en situaciones de alto riesgo, representa un desafío logístico complejo debido a la variabilidad en la generación de estos residuos y la necesidad de minimizar los riesgos asociados a su manejo. Para abordar este problema, se han utilizado modelos de optimización estocástica que consideran la incertidumbre en la generación de residuos y las restricciones logísticas involucradas.

Un estudio reciente sobre este tema es el artículo de Wang et al. [19], titulado "A Stochastic Inventory Routing Problem for Infectious Medical Waste Collection", el cual presenta un modelo de programación estocástica enfocado en la optimización de la recolección de residuos médicos. Este modelo permite minimizar costos y riesgos al determinar rutas eficientes para la recolección y transporte de estos materiales peligrosos, teniendo en cuenta la incertidumbre en la cantidad y frecuencia de generación de residuos.

Este enfoque combina técnicas de programación estocástica y modelos de inventario, y se aplica en la optimización de rutas de vehículos (VRP) en contextos donde la seguridad y eficiencia en la recolección de residuos médicos son primordiales. Los resultados de este modelo mejoran la eficiencia operativa en la gestión de residuos infecciosos en hospitales y otros entornos de salud, proporcionando un marco sólido para la toma de decisiones en la logística de residuos en el sector salud.

2.3 Enjambre de Partículas (PSO)

Una variante híbrida del algoritmo de Enjambre de Partículas ha mostrado ser efectiva en la resolución de problemas NP-hard en la gestión de recursos médicos, mejorando la eficiencia en la programación de turnos y asignación de equipos en hospitales [16].

Gao y Lin [6] aplicaron el algoritmo de Enjambre de Partículas (PSO) para resolver el problema de programación de turnos de enfermería, un desafío caracterizado por numerosas restricciones relacionadas con la satisfacción del personal y la eficiencia operativa. Este enfoque tiene en cuenta no solo las regulaciones administrativas y hospitalarias, sino también el bienestar del personal, optimizando así los turnos para maximizar la satisfacción laboral. El PSO se utiliza para identificar el horario más adecuado para el

personal de enfermería, mejorando la estabilidad y eficiencia en sus turnos.

2.4 Optimización por Colonia de Hormigas (ACO)

Li et al. [21] exploran el uso de la inteligencia artificial y el aprendizaje profundo en la toma de decisiones clínicas y en el diagnóstico médico. Aunque no directamente relacionado con ACO, este estudio ofrece una perspectiva sobre cómo las técnicas de optimización pueden integrarse en sistemas avanzados para mejorar la atención de salud y el manejo de recursos hospitalarios.

Kumar y Prasad [9] investigaron el uso de la Optimización por Colonia de Hormigas (ACO) para la gestión de la cadena de suministro en el sector de la salud. ACO demostró ser eficaz en la optimización logística, permitiendo mejorar la eficiencia en la gestión de inventarios y reducir los costos operativos en hospitales. Este enfoque es particularmente útil para mantener la disponibilidad constante de suministros médicos, esencial en la atención de calidad.

Ganji y Abadeh [5] aplicaron un sistema de clasificación difusa basado en ACO, denominado FCS-ANTMINER, para el diagnóstico de la diabetes. Este sistema emplea reglas difusas para la clasificación de datos de pacientes, alcanzando una precisión de clasificación del 84.24%, lo cual demuestra su efectividad en comparación con otros métodos. Este enfoque permite a los médicos mejorar el pronóstico y el tratamiento, resaltando el potencial de ACO en aplicaciones de diagnóstico médico, donde la precisión y la interpretabilidad son esenciales.

Gambardella et al. [4] desarrollaron un sistema de colonia de hormigas (ACS) para resolver problemas de enrutamiento de vehículos con restricciones de tiempo, demostrando la eficacia de ACO en problemas logísticos complejos. Aunque originalmente aplicado al enrutamiento de vehículos, este enfoque es adaptable a aplicaciones en el sector salud, como el enrutamiento de ambulancias y la logística de suministros médicos, donde cumplir con ventanas de tiempo es crucial.

2.5 Modelos de Colas Multiclase para la Optimización en Emergencias

Nambiar et al. [12] desarrollaron un modelo de colas multiclase con tiempos de servicio dependientes de la carga de trabajo para optimizar la asignación de personal en departamentos de emergencia. Este enfoque reduce el tiempo promedio de estancia de los pacientes en el ED, aumentando la seguridad y satisfacción del paciente.

2.6 Recocido Simulado y Aprendizaje por Refuerzo en la Programación de Turnos de Enfermería

Muklason et al. [11] aplicaron un algoritmo de recocido simulado junto con aprendizaje por refuerzo para la optimización de turnos de enfermería. Este método mejoró la eficiencia en un 82% en comparación con enfoques tradicionales, promoviendo la satisfacción laboral y reduciendo el agotamiento del personal.

2.7 Harris Hawks Optimization (HHO) en el Enrutamiento de Ambulancias

Hussein et al. [7] aplicaron el algoritmo Harris Hawks Optimization (HHO) para optimizar el enrutamiento de ambulancias en ciudades inteligentes, mejorando significativamente los tiempos de respuesta en situaciones de emergencia. Además, Nordin et al. [13] emplearon el algoritmo A* en el enrutamiento de ambulancias en entornos urbanos, mostrando una reducción en tiempos de respuesta a través de un enfoque de búsqueda informada y optimización.

2.8 Algoritmo de Ambulancia Inteligente en la Optimización de Respuesta de Emergencia

Abdeen et al. [1] propusieron un sistema de "ambulancia inteligente" utilizando conectividad 5G y modelos de colas para optimizar el tiempo de respuesta y reducir el tiempo de espera en emergencias en ciudades modernas. Este sistema demuestra mejoras en la eficiencia de servicios de emergencia al optimizar la asignación y priorización de rutas y hospitales menos congestionados.

2.9 LEPST en la Simulación para Optimización de Quirófanos

Arnaut y Kulbashian [2] desarrollaron una heurística, llamada LEPST, para maximizar la utilización de quirófanos mediante la simulación de tiempos de procesamiento estocásticos y tiempos de preparación. El algoritmo supera métodos existentes en eficiencia, proporcionando un enfoque efectivo para la programación de operaciones quirúrgicas en hospitales.

2.10 Programación Matemática y Análisis Multicriterio en la Asignación de Recursos Hospitalarios

Viswanadham y Balaji [18] introdujeron métodos de programación matemática y análisis multicriterio para optimizar la asignación de recursos limitados en hospitales. Su modelo permite una reducción de costos operativos en un 10%, mejorando la eficiencia y la calidad de la atención médica.

2.11 Factor de Probabilidad de Complicación (CPF) en la Optimización de Tratamientos de Radioterapia

Wolbarst et al. [20] propusieron un enfoque basado en el Factor de Probabilidad de Complicación (CPF) para la planificación de tratamientos de radioterapia. Este enfoque mejora la distribución de dosis y reduce las complicaciones, optimizando la efectividad de los tratamientos de radioterapia.

2.12 Programación Mixta-Entera No Lineal (MINLP) en la Optimización de Regímenes de Quimioterapia

Bräutigam [3] aplicó programación entera mixta no lineal (MINLP) para optimizar regímenes de quimioterapia, utilizando el modelo de crecimiento tumoral de Gompertz. El modelo permite una administración adaptativa de dosis, controlando el tamaño del tumor

y reduciendo efectos secundarios, lo cual mejora la calidad de vida del paciente.

2.13 Algoritmos Genéticos

Los algoritmos genéticos (GA) son una técnica de optimización inspirada en la evolución natural, que se ha demostrado efectiva en problemas donde el espacio de soluciones es extenso y existen múltiples restricciones. En el sector salud, los GA se aplican exitosamente para gestionar recursos en situaciones críticas, tales como la cadena de suministro de hospitales y la asignación de citas, optimizando el uso de inventarios y reduciendo los costos asociados.

Lee et al. [10] presentaron un modelo de programación mixta-entera integrado con algoritmos genéticos para la optimización de la cadena de suministro hospitalaria. Este modelo aborda desafíos como la gestión de inventarios y la distribución de suministros, los cuales requieren equilibrio entre costos y disponibilidad constante de recursos críticos en hospitales. La metodología de Lee et al. permite optimizar el costo en inventarios y transporte hasta en un 8%, garantizando así una disponibilidad constante de suministros médicos esenciales en hospitales.

Para ilustrar este enfoque, a continuación se presenta un ejemplo simplificado de implementación de un algoritmo genético en Python para la optimización de inventarios:

```
1 import random
2 # Configuración de parámetros
3 population_size = 500 # Tamaño de la población
4 generations = 100 # Número de generaciones
5 mutation_rate = 0.1 # Tasa de mutación
6 elite_size = 10 # Tamaño de la elite
7
8 # Genera una configuración inicial de inventario
9 def generate_individual():
10     return [random.randint(1, 100) for _ in
11             range(10)] # Cada posición representa un
12             producto
13
14 # Función de aptitud que minimiza el costo
15 def fitness(individual):
16     cost = sum(individual) # Simplificación del
17     costo total
18     # Penalización si algún suministro es escaso
19     if any(item < 10 for item in individual):
20         return cost + 1000
21     return cost
22
23 # Cruce entre dos individuos
24 def crossover(parent1, parent2):
25     # Punto aleatorio para el cruce
26     point = random.randint(1, len(parent1) - 1)
27     return parent1[:point] + parent2[point:]
28
29 # Mutación
30 def mutate(individual):
```

```

28     for i in range(len(individual)):
29         if random.random() < mutation_rate:
30             individual[i] = random.randint(1,
31                 100) # Mutacion aleatoria en el
32                 rango de inventario
33
34 # Algoritmo Genetico
35 population = [generate_individual() for _ in
36     range(population_size)]
37 best_cost_per_generation = [] # Para seguimiento
38     del mejor costo en cada generacion
39
40 for generation in range(generations):
41     # Ordena la poblacion por aptitud (de menor
42     a mayor costo)
43     population = sorted(population, key=fitness)
44
45     # Registra el mejor costo de la generacion
46     actual
47     best_cost = fitness(population[0])
48     best_cost_per_generation.append(best_cost)
49     print(f"Generacion_{generation}:_Mejor_costo
50         _=_{best_cost}")
51
52     # Seleccin de la elite (los mejores
53     individuos)
54     next_generation = population[:elite_size] #
55     Top elite_size individuos
56
57     # Cruza y muta para llenar la nueva
58     poblacion
59     while len(next_generation) < population_size
60         :
61         parent1, parent2 = random.sample(
62             population[:20], 2) # Seleccin de
63             padres del top 20%
64         offspring = crossover(parent1, parent2)
65         mutate(offspring)
66         next_generation.append(offspring)
67
68     population = next_generation
69
70 # Mejor solucion final
71 best_solution = min(population, key=fitness)
72 print("Mejor_solucion_encontrada:",
73     best_solution)

```

2.13.1 Evaluación del Algoritmo y Pruebas. Para evaluar el rendimiento del algoritmo genético en la optimización de inventario y distribución, se realizaron pruebas variando parámetros clave como el número de generaciones, el tamaño de la población, la tasa de

mutación y el tamaño de la élite. Los resultados de estas pruebas, presentados en la Tabla.

- **Tamaño de la población:** Aumentar la población a 1000 (Prueba 5) mejoró ligeramente la diversidad de soluciones, pero el costo total se mantuvo similar al obtenido con una población de 500. Esto sugiere que una población de 500 es suficiente para este problema sin incrementar innecesariamente el tiempo de procesamiento.
- **Tasa de mutación:** Disminuir la tasa de mutación a 0.05 (Prueba 6) ayudó a una convergencia más rápida sin comprometer la calidad de las soluciones. En contraste, aumentar la mutación a 0.2 (Prueba 7) generó una mayor variabilidad, aunque aumentó el riesgo de obtener costos subóptimos debido a cambios excesivos.
- **Tamaño de la élite:** Usar una élite de 20 individuos (Prueba 9) proporcionó una mejor retención de soluciones óptimas, lo cual ayudó a acelerar la convergencia del algoritmo. En comparación, una élite de 5 (Prueba 8) resultó en una menor estabilidad en los resultados. Por tanto, el tamaño de élite ideal parece estar entre 10 y 20 para este problema, logrando un equilibrio adecuado entre explotación y exploración.

Table 1: Comparación de Parámetros en el Algoritmo Genético para Optimización de Inventario y Distribución

| Prueba | Gen. | Pob. | Mut. | Élite | C.T. | Inv | Dist. |
|--------|------|------|------|-------|------|-----|-------|
| 1 | 50 | 500 | 0.1 | 10 | 112 | 101 | 11 |
| 2 | 100 | 500 | 0.1 | 10 | 110 | 100 | 10 |
| 3 | 200 | 500 | 0.1 | 10 | 110 | 100 | 10 |
| 4 | 100 | 100 | 0.1 | 10 | 121 | 107 | 14 |
| 5 | 100 | 1000 | 0.1 | 10 | 110 | 100 | 10 |
| 6 | 100 | 500 | 0.05 | 10 | 110 | 100 | 10 |
| 7 | 100 | 500 | 0.2 | 10 | 123 | 108 | 15 |
| 8 | 100 | 500 | 0.1 | 5 | 110 | 100 | 10 |
| 9 | 100 | 500 | 0.1 | 20 | 110 | 100 | 10 |

Adicionalmente, Podgorelec y Kokol [14] desarrollaron un sistema basado en algoritmos genéticos para la programación de pacientes en situaciones altamente restringidas, lo cual aborda directamente las limitaciones en el tiempo y recursos en la planificación de citas médicas. Su enfoque se centra en maximizar el número de citas asignadas respetando la disponibilidad del personal y los recursos médicos, un problema crítico en entornos hospitalarios con alta demanda.

Un estudio reciente utiliza un algoritmo genético para optimizar la planificación de tratamientos de radioterapia en pacientes con cáncer, logrando mejorar la asignación de dosis para maximizar la eficacia del tratamiento mientras se minimizan los efectos secundarios [15]. Este enfoque demuestra el potencial de los algoritmos genéticos en el ámbito de la salud, especialmente en problemas de optimización complejos donde la precisión y la eficiencia son cruciales.

3 Metodología de la Investigación

3.1 Revisión Sistemática de la Literatura

Para realizar la revisión sistemática, se seleccionaron artículos relevantes en bases de datos académicas como IEEE Xplore, ScienceDirect y Google Scholar, empleando términos de búsqueda específicos como "algoritmos de optimización en salud" y "problemas NP en medicina". Esta búsqueda resultó en una selección de 21 artículos clave que se enfocan en el uso de técnicas de optimización para resolver problemas complejos en el sector salud.

Cada artículo fue evaluado de acuerdo a su relevancia y aplicabilidad en problemas de optimización de alta complejidad en salud. La revisión abarcó diversas técnicas de optimización, incluyendo:

Algoritmos genéticos (GA), utilizados en la optimización de inventarios y recursos hospitalarios. Programación estocástica, aplicada en la programación de citas y en la gestión de incertidumbres. Optimización por Colonia de Hormigas (ACO), orientada al enrutamiento de vehículos y la logística de suministros. Recocido simulado y Simulación para la planificación de turnos y asignación de recursos. Algoritmo Harris Hawks Optimization (HHO), empleado para mejorar tiempos de respuesta en situaciones de emergencia, entre otros.

4 Conclusión

Este estudio destaca el valor de los algoritmos de optimización, particularmente los algoritmos genéticos (GA), en la resolución de problemas complejos en el sector salud, como la asignación de recursos y la optimización de inventarios y turnos. Los GA han demostrado ser efectivos para navegar espacios de solución amplios y gestionar múltiples restricciones. Sin embargo, su aplicación presenta desafíos, como la necesidad de ajustar sus parámetros cuidadosamente y el tiempo de procesamiento, que puede ser considerable en entornos de alta demanda.

References

- [1] M. A. R. Abdeen et al. 2024. A Novel Smart Ambulance System—Algorithm Design, Modeling, and Performance Analysis. *Proceedings of the 2011 IEEE Colloquium on Humanities, Science and Engineering* (2024).
- [2] J. P. Arnaout and S. Kulbashian. 2008. Maximizing the utilization of operating rooms with stochastic times using simulation. *Proceedings of the Winter Simulation Conference* (2008).
- [3] K. Bräutigam. 2024. Optimization of Chemotherapy Regimens Using Mathematical Programming. *Computers & Industrial Engineering* 191 (2024). <https://doi.org/10.1016/j.cie.2024.110078>
- [4] Luca Maria Gambardella, Éric Taillard, and Giovanni Agazzi. 2000. Ant colony system for vehicle routing problems with time windows. *European Journal of Operational Research* 123, 1 (2000). [https://doi.org/10.1016/S0933-3657\(00\)00006-2](https://doi.org/10.1016/S0933-3657(00)00006-2)
- [5] Mostafa Fathi Ganji and Mohammad Saniee Abadeh. 2011. A fuzzy classification system based on Ant Colony Optimization for diabetes disease diagnosis. *Expert Systems with Applications* 38, 12 (2011). <https://doi.org/10.1016/j.eswa.2011.05.018>
- [6] Shiou-Ching Gao and Chun-Wei Lin. 2013. Particle Swarm Optimization Based Nurses' Shift Scheduling. *Springer* (2013), 775–782. https://doi.org/10.1007/978-981-4451-98-7_93
- [7] Taha Darwassh Hanawy Hussein, Mondher Frikha, and Javad Rahebi. 2023. Harris Hawks Optimization for Ambulance Vehicle Routing in Smart Cities. *Eastern-European Journal of Enterprise Technologies* 2, 3 (122) (2023). <https://doi.org/10.15587/1729-4061.2023.278002>
- [8] Soheyl Khalilpourazari. 2024. Advanced Stochastic Programming and Machine Learning Models for Healthcare Planning, Scheduling, and Prediction Problems. *Concordia University Spectrum* (2024). <https://spectrum.library.concordia.ca/id/eprint/993950/>
- [9] Senthil Kumar and Venkata Prasad. 2011. Ant Colony Optimization for healthcare supply chain management. *Expert Systems with Applications* 38, 3 (2011), 3139–3146. <https://doi.org/10.1016/j.eswa.2010.08.128>
- [10] Y. H. Lee, D. W. Cho, and S. W. Lee. 2012. Optimization of Healthcare Supply Chain using Integrated Inventory and Distribution Planning. *International Journal on Information* (2012).
- [11] A. Muklason et al. 2023. Solving Nurse Rostering Optimization Problem using Reinforcement Learning - Simulated Annealing with Reheating Hyper-heuristics Algorithm. *Procedia Computer Science* (2022).
- [12] S. Nambiar, M. E. Mayorga, and Y. Liu. 2022. Routing and Staffing in Emergency Departments: A Multiclass Queueing Model with Workload Dependent Service Times. *IIE Transactions on Healthcare Systems Engineering* (2022).
- [13] A. Nordin, N. A. Kadir, and Z. A. Zaharudin. 2011. An application of the A* algorithm on the ambulance routing. *Proceedings of the 2011 IEEE Colloquium on Humanities, Science and Engineering, Penang, Malaysia* (2011).
- [14] V. Podgorelec and P. Kokol. 1997. Genetic Algorithm Based System for Patient Scheduling in Highly Constrained Situations. *Journal of Medical Systems* 21, 6 (1997). <https://doi.org/10.1023/a:1022828414460>
- [15] Author Names (replace with actual authors). 2022. A Genetic Algorithm for Optimizing Radiation Therapy Treatment Planning for Cancer Patients. *Current Oncology* 29, 6 (2022). <https://doi.org/10.3390/curroncol29060318>
- [16] Simran. 2023. A Hybrid Particle Swarm Optimization Algorithm for Solving NP-Hard Problems in Healthcare. *IEEE Xplore* (2023). <https://doi.org/10.1109/ASIANCON58793.2023.10270025>
- [17] Y. Sun et al. 2021. Stochastic Programming for Outpatient Scheduling with Flexible Inpatient Exam Accommodation. *Health Care Management Science* (2021).
- [18] N. Viswanadham and K. Balaji. 2024. Resource Allocation for Healthcare Organizations: Strategies and Implications. *International Journal of Healthcare Management* (2024).
- [19] Xiao Wang, Xin Zhao, Heng Qin, and Lianchun Hu. 2023. A Stochastic Inventory Routing Problem for Infectious Medical Waste Collection. *Networks* (2023). <https://doi.org/10.1002/net.21523>
- [20] Anthony B. Wolbarst, Edward S. Sternick, Bruce H. Curran, and Anatoly Dritschilo. 1980. Optimized Radiotherapy Treatment Planning Using the Complication Probability Factor (CPF). *International Journal of Radiation Oncology*Biophysics* 6, 8 (1980). [https://doi.org/10.1016/0360-3016\(80\)90229-1](https://doi.org/10.1016/0360-3016(80)90229-1)
- [21] Y. Xiang, X. Li, Y. Jin, and X. Yang. 2020. Path Optimization of Medical Waste Transport Routes in the Emergent Public Health Event of COVID-19: A Hybrid Optimization Algorithm Based on the Immune-Ant Colony Algorithm. *International Journal of Environmental Research and Public Health* 17, 16 (2020). <https://doi.org/10.3390/ijerph17165831>

Received 12 September 2024; revised 7 November 2024; accepted 7 November 2024